

Задание 6. Логистическая регрессия

(подробней см. в [1, стр. 93–113], [2, стр. 187–197], [3, стр. 62–67], [4, 5])

(документация: [API Reference — scikit-learn 1.1.3 documentation](https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression)
[sklearn.linear_model.LogisticRegression — scikit-learn 1.1.3 documentation](https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression)
https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression)

Метод логистической регрессии (также называемый логит-регрессией, logit regression) является методом классификации, несмотря на свое название. Логистическая регрессия возвращает вероятность того, что образец принадлежит к определенному классу, т.е. при предсказании возвращается вещественное число (от 0 до 1), а не только ответ (да/нет). Метод используют в задачах, в которых важен не только ответ, но и еще оценка вероятности, например, будет возвращен кредит, пойдет дождь или риск заболевания болезнью с вероятностью такой-то.

Постановка задачи такая же, как и для всех остальных линейных моделей. У нас есть обучающая выборка $X = (x_i, y_i)_{i=1}^l$, где $x_i \in R^n$ – набор из l объектов, у каждого такого объекта x_i есть n признаков $f_j(x_i)$ ($j = 1..n$), известные ответы обучающей выборки – это один из двух классов $y_i \in \{-1, +1\}$.

В линейной модели **классификации** решение ищется в виде функции знака числа (sign) от суммы всех признаков $f_j(x)$ с коэффициентами w_j :

$$a(x, w) = \text{sign} \langle x, w \rangle = \text{sign} \left(\sum_{j=1}^n f_j(x) w_j \right).$$

В этой задаче определить функцию потерь для каждой точки x_i можно как пороговую (количество ошибок):


$$L(a, y) = [\langle x_i, w \rangle y_i < 0].$$

Вместо пороговой функции потерь используют ее непрерывные аппроксимации:

$$L(a, y) = [\langle x_i, w \rangle y_i < 0] \leq L(\langle x_i, w \rangle y_i),$$

где $M_i(w) = (\langle x_i, w \rangle) y_i$ – **отступ** (margin) объекта x_i . При положительном отступе нет ошибки, при отрицательном отступе ошибка есть.

И в случае **метода логистической регрессии** выбирается функция потерь $L(t) = \log_2(1 + e^{-t})$. На рисунке она отмечена синим цветом (log loss). График ее близок к графику функции потерь шарнирной функции для метода опорных векторов, но она является дифференцируемой. Она также как и шарнирная функция потерь штрафует и за правильные ответы, тем больше, чем ближе точка к границе классов.



И также как и в остальных методах просуммировав ее для всех точек, получим функционал качества:

$$Q(w) = \sum_{i=1}^l L(\langle x_i, w \rangle y_i) = \sum_{i=1}^l \log_2(1 + e^{-\langle x_i, w \rangle y_i}) \rightarrow \min_w.$$

Также как и для других методов для борьбы с увеличением весов применяют **регуляризацию** L_2 (сокращает веса линейно зависящих признаков):

$$Q(w) = \sum_{i=1}^l L(\langle x_i, w \rangle y_i) + \tau \sum_{j=1}^n w_j^2 \rightarrow \min_w$$

или регуляризацию L_1 (обнуляет веса неинформативных признаков):

$$Q(w) = \sum_{i=1}^l L(\langle x_i, w \rangle y_i) + \tau \sum_{j=1}^n |w_j| \rightarrow \min_w$$

или их комбинацию (ElasticNet):

$$Q(w) = \sum_{i=1}^l L(\langle x_i, w \rangle y_i) + \tau_1 \sum_{j=1}^n w_j^2 + \tau_2 \sum_{j=1}^n |w_j| \rightarrow \min_w$$


Находить минимум можно с помощью разных вариантов метода градиентного спуска, например стохастическим градиентом.

Кроме определения к какому классу относится точка по формуле $a(x, w) = \text{sign} \langle x, w \rangle$, логистическая регрессионная модель оценивает еще **вероятность** принадлежности точки x к классу $y = 1$ по формуле:

$$p(y = 1 | x; w) = \sigma(\langle x, w \rangle),$$

где $\sigma(t)$ – это **логистическая сигмоидальная функция**:

$$\sigma(t) = \frac{1}{1 + e^{-t}},$$



которая любое вещественное значение переводит в отрезок $[0, 1]$. Если больше нуля $\langle x, w \rangle > 0$, т.е. метод относит точку к классу $+1$, то вероятность $p > 0.5$ и растет до 1 с увеличением расстояния от границы. И, наоборот, если $\langle x, w \rangle$ меньше нуля, т.е. метод относит точку к классу -1 , то вероятность $p < 0.5$.

Вероятность принадлежности к классу 0 определяется:

$$p(y = 0 | x; w) = 1 - p(y = 1 | x; w) = 1 - \sigma(\langle x, w \rangle) = \sigma(-\langle x, w \rangle),$$

так чтобы сумма вероятностей для двух классов равнялась 1.

Обоснование функции потерь для логистической регрессии. Если предполагать, что наша выборка есть выборка независимых наблюдений $X = (x_i, y_i)_{i=1}^l$ с плотностью распределения $p(y | x; w)$, то из принципа максимального правдоподобия требуем, чтобы произведение вероятностей для отдельных точек было максимальным:

$$L(w) = \prod_{i=1}^l p(y_i | x_i; w) \rightarrow \max_w$$

Удобней искать максимум не произведения, а суммы, поэтому прологарифмируем эту функцию и перейдем:

$$L(w) = \log \prod_{i=1}^l p(y_i | x_i; w) = \sum_{i=1}^l \log p(y_i | x_i; w) \rightarrow \max_w$$

Вероятность для одной точки можно посчитать как сигмоиду от отступа:

$$\begin{aligned} p(y_i | x_i; w) &= \frac{y_i + 1}{2} \sigma(\langle x_i, w \rangle) + \frac{y_i - 1}{2} \sigma(-\langle x_i, w \rangle) = \\ &= \sigma(\langle x_i, w \rangle y_i) = \frac{1}{1 + e^{-\langle x_i, w \rangle y_i}}. \end{aligned}$$

И тогда

$$L(w) = \sum_{i=1}^l \log \frac{1}{1 + e^{-\langle x_i, w \rangle y_i}} = - \sum_{i=1}^l \log(1 + e^{-\langle x_i, w \rangle y_i}) \rightarrow \max_w$$

и можно от поиска максимума перейти к поиску минимума:

$$L(w) = \sum_{i=1}^l \log(1 + e^{-\langle x_i, w \rangle y_i}) \rightarrow \min_w$$

И мы получили минимизацию того же функционала.

II. В библиотеке **Scikit-Learn** реализован метод **логистической регрессии** в классе `sklearn.linear_model.LogisticRegression` ([sklearn.linear_model.LogisticRegression — scikit-learn 1.1.3 documentation](#)) и `sklearn.linear_model.LogisticRegressionCV` ([sklearn.linear_model.LogisticRegressionCV — scikit-learn 1.1.3 documentation](#)). Описание метода в документации пакета Scikit-Learn можно посмотреть [1.1. Linear Models — scikit-learn 1.1.3 documentation](#).

Задания

I. Прочитайте пункт “Метод логистической регрессии” и рекомендуемую литературу и ответьте на вопросы:

- 1) Чем метод отличается от других линейных методов?
- 2) По какой формуле при предсказании вычисляется вероятность?
- 3) Какие основные параметры метода в библиотеке Scikit-Learn?
- 4) Какие преимущества и недостатки метода?

II. Выполните задание из файла "statement-logistic.pdf".

Литература

- [1] Рашка Себастьян, Мирджалили Вахид Python и машинное обучение: машинное и глубокое обучение с использованием Python, scikit-learn и TensorFlow 2, 3-е изд.: Пер. с англ. СПб. : ООО "Диалектика", 2020. 848 с.
- [2] Жерон, Орельен. Прикладное машинное обучение с помощью Scikit-Learn и TensorFlow: концепции, инструменты и техники для создания интеллектуальных систем. Пер. с англ. СПб.: ООО Альфа-книга: 2018. 688 с.
- [3] К.В. Воронцов Математические методы обучения по прецедентам (теория обучения машин). 141 с. (Voron-ML-1.pdf)

- [4] Машинное обучение (курс лекций, К.В.Воронцов): [Логистическая регрессия \(machinelearning.ru\)](http://machinelearning.ru).
“Машинное обучение. Линейные методы. К.В. Воронцов, Школа анализа данных, Яндекс”: <https://youtu.be/QIktmPA8nb0?t=3395>
“Линейные методы классификации. Логистическая регрессия”: <https://www.youtube.com/watch?v=VBmfuf11N-M>)
- [5] Крис Элбон Машинное обучение с использованием Python. Сборник рецептов. Пер. с англ. СПб. : БХВ-Петербург, 2019. 384 с.